

1.1 矩阵的基本运算.

① 矩阵相加, 矩阵相乘

② 幂等矩阵: (idempotent matrix) $A^2 = AA = A$

对合矩阵: (involution matrix) $A^2 = AA = I$

③ 矩阵泰勒展开与导数

$$\exp(At) = I + At + \frac{1}{2!}(At)^2 + \frac{1}{3!}(At)^3 + \dots$$

$$\frac{d}{dt} \exp(At) = A \exp(At) = \exp(At) A$$

④ 奇异(非奇异)矩阵 (vertible / invertible matrix)

⑤ 初等行运算 (3种)

若A通过初等行运算换成矩阵B, 则认为A, B为行等价矩阵

⑥ 首元素, 与阶梯型矩阵 (leading entry & echelon matrix)

简约阶梯型矩阵 (reduced echelon matrix) 及其唯一性.

⑦ 矩阵方程求解与增广矩阵.

1.2 向量, 内积空间与线性映射.

① 向量空间: 闭合性, 加法公理, 标量乘法公理.

② 空间V与子空间A, B, 直接求和: $V = A \oplus B \Leftarrow A \cap B = \{0\} \quad A+B=V$

③ 实内积空间: a) 正定性 (positive definite) b) 对称性 (symmetry)

c) 分配律 \rightarrow d) 线性性 (linearity)

欧氏空间 (Euclidean space)

④ 实内积空间内范数

⑤ 复内积空间 a) 正定性 (positive definite) b) 共轭对称性 (Conjugate Symmetry)

c) 分配律 \rightarrow d) 线性性 (linearity)

- ⑥ 线性映射 (变换), 单映射, 单射 (injective) 满射 (surjective)
双射 (bijective)

1.3 随机向量

① 概率密度函数

② 随机向量的统计描述:

数学期望 (expectation) $\vec{\mu}_{(\xi)} = E(\vec{\xi})$

自相关矩阵: (self-correlation matrix) $R_{(\xi)} = E(\vec{\xi} \vec{\xi}^H)$ 共轭对称.

自协方差矩阵: (self-covariance matrix) $C_{(\xi)} = E[(\vec{\xi} - \vec{\mu}_{\xi})(\vec{\xi} - \vec{\mu}_{\xi})^H]$ 共轭对称.

③ 两随机向量之间关系

互相关矩阵 (correlation matrix) $R_{(\xi_1, \xi_2)} = E(\vec{\xi}_1 \vec{\xi}_2^H)$

互协方差矩阵 (covariance matrix) $C_{(\xi_1, \xi_2)} = E[(\vec{\xi}_1 - \vec{\mu}_{\xi_1})(\vec{\xi}_2 - \vec{\mu}_{\xi_2})^H]$

相关系数 (correlation coefficient) $\rho_{(\xi_1, \xi_2)} = \frac{C_{(\xi_1, \xi_2)}}{\sqrt{E(|\xi_1|^2)} \sqrt{E(|\xi_2|^2)}} \in [0, 1]$

④ 其它概念:

统计不相关 \Leftarrow 协方差矩阵为零.

正交 \Leftarrow 互相关矩阵为零.

$$\frac{E[(\xi_1 - E\xi_1)(\xi_2 - E\xi_2)]}{\sqrt{E[(\xi_1 - E\xi_1)^2]} \sqrt{E[(\xi_2 - E\xi_2)^2]}}$$

// $\frac{\text{cov}(\xi_1, \xi_2)}{\text{var}(\xi_1) \text{var}(\xi_2)}$

⑤ 正态随机向量: $x \sim N(\vec{\mu}, \Gamma)$, m 维:

$$f(x) = \frac{1}{(2\pi)^{m/2} |\Gamma|^{1/2}} \exp\left[-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Gamma^{-1} (\vec{x} - \vec{\mu})\right]$$

1.4 内积与范数:

① 内积: a) 非负性 (semi-positive definite) b) 可加性 c) 齐次性
d) Hermitian 性 $\langle \vec{x}, \vec{y} \rangle = \langle \vec{y}, \vec{x} \rangle^*$

② 范数: a) 非负性 (semi-positive definite) b) 齐次性 c) 三角不等式

③ 向量 p -范数: $\|\vec{x}\|_p = \left(\sum_{i=1}^m |\vec{x}_i|^p \right)^{1/p}$

④ 不变性: 若范数 $\|\cdot\|$ 满足 $\|U\vec{x}\| = \|\vec{x}\|$ 对 \forall 向量 \vec{x} 及酉矩阵 U 成立

⑤ 随机向量内积与范数: $\langle \vec{z}_1, \vec{z}_2 \rangle \stackrel{\text{def}}{=} E(\vec{z}_1^H \vec{z}_2)$

⑥ 向量相近量度

a) 欧氏距离: Euclidean Distance

b) Mahalanobis 距离: 对观测向量 $\{\vec{S}_i\}_{i=1,2,\dots,N}$, 求协方差

$$\vec{m} = \frac{1}{N} \sum_{i=1}^N \vec{S}_i, \quad C = \frac{1}{N} \sum_{i=1}^N (\vec{S}_i - \vec{m})(\vec{S}_i - \vec{m})^T$$

未知向量 \vec{x} 到 \vec{m} 的 Mahalanobis 距离为 $(\vec{x} - \vec{m})^T C^{-1} (\vec{x} - \vec{m})$

c) 余弦距离: cosine distance.

⑦ 向量范数用作 Lyapunov 函数

⑧: 矩阵范数: a) 正定性 b) 齐次性 c) 三角不等式 d) $\|AB\| \leq \|A\| \|B\|$

Frobenius 范数: $\|A\|_F \stackrel{\text{def}}{=} \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2}$

l_p 范数: $\|A\|_p \stackrel{\text{def}}{=} \frac{\|A\vec{x}\|_p}{\|\vec{x}\|_p}$

谱范数 (spectral norm) $\|A\|_{\text{spec}} = \sigma_{\max}$

⑨ 矩阵内积: 对 $\forall A, B$, 形状相同:

$$\langle A, B \rangle \stackrel{\text{def}}{=} A^H B$$

1.5 基与 Gram-Schmidt 正交化.

① 线性空间基向量的定义 (basis vectors)

对偶基: $\{\alpha_1, \alpha_2, \alpha_3 \dots \alpha_n\}, \{\beta_1, \beta_2, \beta_3 \dots \beta_n\}$, $\alpha_i^H \beta_j = \delta_{ij}$ 对 $i \in \{1, 2, \dots, n\}$

② 标准正交基向量 (orthonormal basis vectors)

③ Gram-Schmidt 正交化: 从基向量到标准正交基: $\{x_i\} \Rightarrow \{u_i\}$

$$\vec{p}_1 = \vec{x}_1, \quad \vec{u}_1 = \frac{\vec{p}_1}{\|\vec{p}_1\|};$$

$$\vec{p}_k = \vec{x}_k - \sum_{i=1}^k \langle \vec{u}_i, \vec{x}_k \rangle \cdot \vec{u}_i, \quad \vec{u}_k = \frac{\vec{p}_k}{\|\vec{p}_k\|}.$$

1.6. 矩阵标量函数.

① 二次型: $x^H A x$, 一般假设 A 共轭对称,

② 正定矩阵. etc

给定 $m \times n$ 矩阵 J 与 $n \times n$ 对称矩阵 H , $x^H H x > 0$ 对 $\forall x$ 满足 $Jx = 0$ 的成立. 则 \exists 有限大的 $\rho > 0$, s.t. $H + \bar{\rho} J J^H$ 对 $\forall \bar{\rho} > \rho$ 正定.

③ 矩阵的 Trace, 限适用于方阵

$$\text{tr}(AB) = \text{tr}(BA)$$

$$\text{tr}(BAB^{-1}) = \text{tr}(B^{-1}AB) = \text{tr}(A), \quad A, B \text{ 方阵, } B \text{ 非奇异}$$

$$\text{tr}(A x x^H) = x^H A x; \quad y^H x = \text{tr}(x y^H)$$

$$\text{tr}(A) = \sum_{i=1}^n \lambda_i \quad \lambda_i \text{ 为特征值}$$

$$\text{tr}(A^k) = \sum_{i=1}^n \lambda_i^k$$

$$\text{tr}[(A^T B)^2] \leq \text{tr}(A^T A) \text{tr}(B^T B)$$

$$\text{tr}(A^2) \leq \text{tr}(A^T A)$$

$$\text{tr}[(A+B)(A+B)^T] \leq 2 [\text{tr}(AA^T) + \text{tr}(BB^T)]$$

④ 行列式

矩阵的余子式 $A_{ij}^{\#} = (-1)^{i+j} \det(A_{ij})$

$$\det(A) = \sum_{j=1}^n a_{ij} (-1)^{i+j} \det(A_{ij})$$

行列式性质:

a) 初等行列变换不改变 $\det(A)$

b) $\det(A) = \det(A^T)$; $\det(A) = \det(A^H)^*$

c) $\det(AB) = \det(A) \det(B)$

d) 正定阵 A 满足 $\det(A) > 0$

e) 若 A, B 均半正定 $\det(A+B) \geq \det(A) + \det(B)$

⑤ 秩 (Rank)

a) 左乘满列秩 / 右乘满行秩 \Rightarrow 秩不变

b) $\text{rank}(A^T A) = \text{rank}(A A^T) = \text{rank}(A)$

$\text{rank}(A^H A) = \text{rank}(A A^H) = \text{rank}(A)$

c) $\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B)$

d) $\text{rank}(A) + \text{rank}(B) - k \leq \text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$

1.7 逆矩阵: 广义逆矩阵

① 逆矩阵与伴随矩阵定义

② (Sherman-Morrison公式) A 为可逆矩阵, x, y 为向量使 $(A + xy^H)$ 可逆

$$(A + xy^H)^{-1} = A^{-1} - \frac{A^{-1} x y^H A^{-1}}{1 + y^H A^{-1} x}$$

③ 左逆矩阵 (left inverse): $LA = I$ & $AL \neq I$

右逆矩阵 (right inverse): $AR = I$ & $RA \neq I$

对于 $M \in \mathbb{R}^{m \times n}$, $m \geq n$ 时才可能有左逆矩阵
 $m \leq n$ 时才可能有右逆矩阵

④ 左伪逆矩阵 (left pseudo inverse) $L = (A^H A)^+ A^H$
 右伪逆矩阵 (right pseudo inverse) $L = A^H (A A^H)^+$

⑤ 线性一致方程与非一致方程
 \downarrow
 $\text{Rank}([A, y]) = \text{Rank}(A)$

⑥ 广义逆矩阵: $x = Gy$ 是一致方程 $Ax = y$ 的通解, 则 G 为 A 的广义逆矩阵 (generalized inverse), 记作 A^-

一致方程 $Ax = y$ 对 y 恒有解 $x = Gy$ 时 iff $AGA = A$

⑦ 性质: 若 A^- 存在, 作 A^-A 和 AA^- 均为幂等矩阵且 $\text{rank} = \text{rank}(A)$

⑧ 满秩分解 (full-rank decomposition) $A = KL$, K 满列秩, L 满行秩
 若 A 满秩分解为 $A = FG$, 则 $A^- = G^T(F^T A G^T)^+ F^T$

⑨ 令 $n \times m$ 矩阵 A^- 是 $m \times n$ 矩阵 A 的任意一个广义逆矩阵, 则

齐次 $Ax = 0$ 通解为 $x = (I - A^-A)z$ z 为任意 $R^{n \times 1}$ 向量

非齐次 $Ax = y$ 通解为 $x = A^-y + (I - A^-A)z$ z 为任意 $R^{n \times 1}$ 向量

Appendix: 任意方阵的“伪逆矩阵” via 特征向量分解

设矩阵 $M \in R^{N \times N}$, 其特征值为 $\lambda_1, \lambda_2, \dots, \lambda_j, \lambda_{j+1}, \dots, \lambda_N$

其中 $\lambda_i \neq 0$ 对 $i < j$ 而 $\lambda_i = 0$ 对 $i \geq j$ 其可以拆解为

$$M = \sum_{i=1}^N \lambda_i v_i v_i^T, \quad v_i \text{ 为 } \lambda_i \text{ 对应特征向量.}$$

伪逆矩阵为 $M^\# = \sum_{i=1}^j \frac{1}{\lambda_i} v_i v_i^T$

均可作定义